


Consideraciones al crear subconjuntos



Consideraciones al crear subconjuntos

- ▶ Es importante dividir el dataset en al menos dos conjuntos
- ▶ Podemos usar la función popular `train_test_split`




2
/
3




El problema con train_test_split

- La selección es aleatoria
- La aleatoriedad es no repetible
- Si tu intención es comparar dos modelos, divisiones similares deben ser usadas



Fair splitting

- Hay fenómenos que están relacionados entre ello
 - Órdenes de entrega en restaurantes
 - Vuelos en un aeropuerto
- Verifica la relación que tienen tus observaciones entre si




Series de tiempo


- ▶ Las observaciones pasadas tienen influencia directa a lo esperado en el futuro
- ▶ La división aleatoria no tiene en cuenta estas relaciones



Series de tiempo dividida aleatoriamente



Series de tiempo dividida justamente



Conclusión

- Asegúrate de que el splitting sea determinístico
- Prevén el data leakage en series de tiempo

